

Sveučilište u Rijeci
Tehnički fakultet
Diplomski sveučilišni studij računarstva

Izborni projekt I

Izborni projekt I - Strojno učenje: Konverzija RGB slika iz hiperspektralnih te rekonstrukcija hiperspektralnih iz RGB slika

Barbara Breš
0069085153



Rijeka, rujan 2022.

Sadržaj


1	Uvod	1
1.1	Metodologija	1
1.1.1	Baza podataka	2
1.1.2	Konverzija hiperspektralnih slika u RGB	2
1.1.3	Podjela podataka i model	2
1.1.4	Rezultati	3
2	Zaključak	7

Popis slika

1.1	Valne duljine hiperspektralnih slika	1
1.2	Mean squared error funkcija	2
1.3	Sažetak modela	3
1.4	Graf 1 - prikaz rekonstrukcije cijelog hiperspektralnog spektra unutar slike	4
1.5	Graf 2 - prikaz rekonstrukcije vidljivog spektra unutar hiperspektralne slike	4
1.6	Originalna slika (lijevo), rekonstruirana slika (desno) - validacijski set	5
1.7	Originalna slika (lijevo), rekonstruirana slika (desno) - trening set	6

1. Uvod

Hiperspektralna slika je slika s vrlo gustim i kontinuiranim spektralnim informacijama za svaki piksel slike. Za razliku od RGB slika, koje imaju 3 kanala (crvena, zelena i plava), hiperspektralne slike imaju preko 100 kanala koji dodatno opisuju informacije prikazane u slici pa se zato često i koriste za pronalaženje predmeta, identificiranje materijala ili otkrivanja procesa na samoj slici. Na slici 1.1 prikazane su valne duljine koje hiperspektralna slika obuhvaća, a to su: vidljivi dio spektra te infracrveni spektar.



Slika 1.1: Valne duljine hiperspektralnih slika

Zadatak projekta bio je osmisлити i implementirati način na koji će se iz hiperspektralnih slika moći izvući podaci o RGB slojevima te pomoću piksela natrag rekonstruirati originalnu hiperspektralnu sliku.

1.1 Metodologija

Prije početka implementacije i osmišljavanja modela s kojim će se rekonstruirati natrag hiperspektralne slike iz RGB slojeva, bilo je potrebno razraditi kako uopće dobiti informacije o RGB slojevima iz samih hiperspektralnih slika. Na slici 1.1 vidljivo je da je RGB zapravo podskup samog hiperspektralnog spektra što znači da dobivanje RGB informacija nije toliko kompleksno. Kompleksniji dio projekta bio je osmisлити na koji način, nakon što se dobiju informacije o RGB pikselima, vratiti piksele natrag u hiperspektralni spektar.

1.1.1 Baza podataka

Baze podataka s hiperspektralnim slikama poprilično je izazovno pronaći na internetu, pogotovo da su javno dostupne. Iz tog razloga, za ovaj projekt korištena je baza podataka Emilio/Norcorr (baza hiperspektralnih slika koju su napravili Talijani i Slovenci), no umanjena za četvrtinu zbog dostupnih resursa i računalne snage na kojoj je model treniran. Sama baza podataka sadržava 53 hiperspektralne slike, što se čini kao malo podataka, no sve te slike će se razložiti na piksele i time će umjesto 53 biti preko milijun podataka (piksela) za samo treniranje modela te preko 100 tisuća podataka (piksela) za validaciju modela. Slike su različitih dimenzija, ali se sve širine i visine okvirno nalaze između 130 i 170, dok sve slike imaju jednak broj od 224 kanala. Navedene slike nalaze se u mapi `out_2` unutar mape samog projekta.

1.1.2 Konverzija hiperspektralnih slika u RGB

Kako je spomenuto već prije, RGB čini podskup unutar hiperspektralnog spektra. Iz tog razloga dobivanje RGB slika iz hiperspektralnih (.h5 datoteka) je trivijalan postupak. Potrebno je pronaći otprilike točnu lokaciju na kojoj se nalaze crveni, zeleni i plavi sloj unutar hiperspektralnih slika. Pošto su slike spremljene unutar polja, potrebno je izračunati indeks na kojem se navedena tri sloja nalaze. Indeksi dobiveni i prikazani u kodu za navedena tri sloja su izvučeni iz prijašnjeg rada kolege Matije Dizdara te podijeljeni s 8 pošto je sama baza podataka umanjena za četvrtinu, a svaki od RGB slojeva je 8 bitni. Tim izračunom dobiveni su indeksi na kojima se nalaze crveni, zeleni i plavi sloj unutar hiperspektralnih slika.

Gore opisanim matematičkim postupkom izvodi se konverzija hiperspektralnih slika oblika (224, širina, visina) u RGB slike oblika (3, širina, visina). Širina i visina ostaju iste kao i kod originalne slike, samo je bilo potrebno smanjiti broj kanala s 224 na 3.

1.1.3 Podjela podataka i model

Originalni hiperspektralni podaci, kao i dobiveni RGB podaci iz njih, podijeljeni su na trening i testne skupove (setove) podataka, od kojih testni sačinjavaju 15% od ukupnih podataka. RGB podaci dani su kao ulazni podaci modelu, pošto je drugi dio projekta rekonstruirati iz RGB podataka što vjerodostojnije hiperspektralne podatke koji će se usporediti s originalnim hiperspektralnim podacima te će se izračunati **loss** tj. postotak odudaranja od originalnog podatka pomoću **Mean squared error** funkcije koja je prikazana na slici 1.2.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \tilde{y}_i)^2$$

Slika 1.2: Mean squared error funkcija

Zbog premalog broja podataka (53 slike), a i jednostavnosti treniranja modela, hiperspektralne kao i RGB slike bilo je potrebno pretprocesirati tj. prebaciti ih u piksele. To je napravljeno pomoću funkcije **toPix** koja prolazi kroz svaku sliku te ju pretvara u piksele. Tako pretprocesirani podaci daju se kao ulazni i izlazni podaci modelu kako bi mogao obaviti treniranje te validaciju na kraju.

Model je baziran na dekođer dijelu autoenkodera pošto je bilo potrebno "napuhati" RGB podatke natrag na hiperspektralne tj. od 3 kanala ponovno dobiti 224. Na slici 1.3 prikazan je sažetak modela.

Model: "model"

Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 3)]	0
dense (Dense)	(None, 14)	56
dense_1 (Dense)	(None, 37)	555
dense_2 (Dense)	(None, 69)	2622
dense_3 (Dense)	(None, 102)	7140
dense_4 (Dense)	(None, 146)	15038
dense_5 (Dense)	(None, 224)	32928
=====		
Total params: 58,339		
Trainable params: 58,339		
Non-trainable params: 0		


Slika 1.3: Sažetak modela

Sam model se sastoji, kao što je i vidljivo iz slike 1.3, od 7 slojeva. Ulazni (input) sloj prima RGB piksele i napuhuje ih dalje do zadnjeg sloja kada im broj kanala s 3 prelazi u 224. Kao što je već i spomenuto, da bi se validiralo koliko sam model točno rekonstruira RGB piksele natrag u hiperspektralne, koristila se Mean squared error funkcija koja izračunava kvadratnu razliku između dva piksela na istoj poziciji.

1.1.4 Rezultati


Model je imao **loss** od 0.0018 tj. 0.18% na trening setu, dok je na validacijskom imao **loss** od oko 0.0016-0.002 tj. 0.16 - 0.2% što su poprilično dobri rezultati. Graf prikazan na slici 1.4 prikazuje plavom linijom **Ground truth** tj. izvorne podatke jedne proizvoljno odabrane slike iz baze podataka, dok narančasta linija

prikazuje modelovu rekonstrukciju iste. Kao što je vidljivo model odlično rekonstruira na intervalu od 20-130 jer se upravo na tom intervalu nalaze slojevi crvene, zelene i plave tj. vidljivog spektra. Informacije iznad 130 pripadaju infracrvenom spektru za kojega je i očekivano da neće biti toliko dobro rekonstruiran pošto sam RGB nema nikakve informacije o njemu jer je infracrveni spektar van njegovog.



Slika 1.4: Graf 1 - prikaz rekonstrukcije cijelog hiperspektralnog spektra unutar slike

Kada bi modelu dali da trenira točno na navedenom intervalu od 20-130 tada bi se dobio graf prikazan na slici 1.5. Kao što je vidljivo, rekonstrukcija je puno bolja za istu sliku što govori i sam **loss** koji iznosi $6.1558e-04$ za trening set i $5.6672e-04$ za validacijski set.



Slika 1.5: Graf 2 - prikaz rekonstrukcije vidljivog spektra unutar hiperspektralne slike

Kako bi se bolje vidjela sama rekonstrukcija, napravljen je mali primjer na primjeru jedne slike iz validacijskog seta. Pošto je ljudskom oku vidljiv samo vidljivi spektar, odlučeno je dobivene rekonstruirane hiperspektralne slike prebaciti opet u RGB pomoću matematičkog postupka navedenog u 1.1.2 dijelu. No prvo je bilo potrebno odvojiti sve hiperspektralne piksele za svaku posebnu sliku. Radi jednostavnosti, odlučeno je u primjeru to prikazati za prvu sliku u validacijskom setu. Prije samog procesa pretprocesiranja slika u piksele, zapamćene su dimenzije za točno tu sliku. Kako su iz navedenog razloga unaprijed poznate dimenzije slike, bilo je potrebno prebaciti sliku u točno taj oblik što je napravljeno kroz par koraka koji su vidljivi u kodu. U srži radi se o prebacivanju vrijednosti piksela unutar svakog reda kako bi se dobile točne boje slike te mijenjanju dimenzija slika kako bi se navedeni pikseli prikazali na točnim pozicijama. Nakon cijelog ovog procesa dobivena je hiperspektralna slika koja je, kao što je već navedeno ranije, pomoću matematičkog postupka prebačena u RGB sliku kako bi ju bilo lakše prikazati. Rekonstruirana slika uspoređena je s originalnom RGB slikom i pomoću **Mean squared error** funkcije izračunata je razlika između navedenih slika. Kao rezultat je dobiveno da se razlikuju za 0.00132 tj. 0.13% što ljudskom oku zapravo i nije lako vidljivo pa se može reći da je rekonstrukcija bila uspješna. Originalna slika (lijevo) i rekonstruirana slika (desno) vidljive su na slici 1.6



Slika 1.6: Originalna slika (lijevo), rekonstruirana slika (desno) - validacijski set

Gore navedenim postupkom prikazana je i jedna slika iz trening seta. Pomoću Mean squared errora izračunata je razlika između originalne slike i rekonstruirane trening slike od 0.000847, što je otprilike 0.08%, a navedena usporedba s originalnom slikom prikazana je na slici 1.7.



Slika 1.7: Originalna slika (lijevo), rekonstruirana slika (desno) - trening set

2. Zaključak

Iz rezultata vidljivo je da konverzija iz hiperspektralnih slika u RGB slike i rekonstrukcija iz RGB u hiperspektralne slike je moguća i donosi dobre rezultate. Jednostavnim metodama htjelo se dokazati da je moguće napraviti poprilično dobru rekonstrukciju i na maloj bazi podataka. Ovaj postupak mogao bi se koristiti za stvaranje vlastitih hiperspektralnih slika te i baza podataka pošto, kao što je rečeno u radu, javno dostupne baze podataka s hiperspektralnim slikama jako je teško pronaći. Korištenjem veće baze hiperspektralnih slika te nadogradnjama na postojeći model mogao bi se riješiti i problem lošijeg rekonstruiranja infracrvenih slojeva unutar hiperspektralnih slika, no to je tema za neki budući rad.